MACHINE LEARNING

ANALISIS KLASIFIKASI DATASET BREAST CANCER WISCONSIN MENGGUNAKAN ALGORITMA K-NEAREST NEIGHBOR

CANDRA SAVIRA 2043231092

Asisten Dosen:

ROBI ARDANA PUTRA, S.TR.STAT

Dosen:

NOVIYANTI SANTOSO, S.SI., M.SI

1. Latar Belakang

Kanker payudara merupakan salah satu jenis kanker yang paling sering terjadi pada perempuan dan menjadi masalah kesehatan yang serius di berbagai negara. Penyakit ini terjadi ketika sel-sel pada jaringan payudara tumbuh secara tidak normal dan tidak terkendali, sehingga dapat membentuk tumor yang bersifat jinak yang disebut benign maupun ganas yang disebut malignant. Kanker payudara yang bersifat ganas dapat menyebar ke bagian tubuh lain dan membahayakan keselamatan pasien apabila tidak dideteksi sejak dini. Oleh karena itu, upaya deteksi dan klasifikasi kanker payudara sangat penting untuk membantu proses diagnosis, menentukan penanganan yang tepat, serta meningkatkan peluang kesembuhan pasien.

Salah satu metode machine learning yang dapat digunakan untuk proses klasifikasi adalah K-Nearest Neighbor (KNN). Metode KNN bekerja dengan cara membandingkan data baru dengan sejumlah data terdekat berdasarkan kemiripan karakteristiknya. Klasifikasi suatu data ditentukan berdasarkan mayoritas kelas dari tetangga terdekat tersebut. KNN merupakan metode yang cukup sederhana, mudah dipahami, dan banyak digunakan dalam penelitian klasifikasi karena tidak memerlukan proses pelatihan model yang terlalu kompleks. Selain itu, metode ini sangat cocok digunakan pada data numerik karena proses klasifikasinya didasarkan pada perhitungan jarak antar data.

Penggunaan metode KNN dalam analisis kanker payudara dinilai tepat karena dataset kanker payudara umumnya terdiri dari variabel-variabel numerik hasil pengukuran medis, seperti ukuran, tekstur, dan karakteristik sel. Data numerik tersebut sesuai dengan prinsip kerja KNN yang mengandalkan kedekatan jarak antar data untuk menentukan kelas diagnosis. Dengan menggunakan metode KNN, data pasien dapat diklasifikasikan ke dalam kategori benign atau malignant berdasarkan kemiripan dengan data pasien sebelumnya. Oleh karena itu, penerapan metode KNN pada dataset kanker payudara diharapkan dapat membantu menghasilkan klasifikasi yang akurat dan mendukung proses analisis dalam bidang kesehatan.

2. Deskripsi Dataset

Dataset terdiri dari data numerik hasil pengukuran sel kanker, dengan variabel target yaitu diagnosis, yang memiliki dua kelas, yaitu B (Benign) dan M (Malignant)

No	Variabel	Deskripsi
1	diagnosis	Status diagnosis kanker payudara (M = malignant/ganas, B = benign/jinak)
2	radius_mean	Rata-rata jarak dari pusat ke titik-titik tepi sel
3	texture_mean	Rata-rata tekstur permukaan sel
4	perimeter_mean	Rata-rata keliling sel
5	area_mean	Rata-rata luas sel
6	smoothness_mean	Rata-rata tingkat kehalusan permukaan sel
7	compactness_mean	Rata-rata tingkat kekompakan sel
8	concavity_mean	Rata-rata tingkat cekungan pada kontur sel
9	concave points_mean	Rata-rata jumlah titik cekung pada kontur sel
10	symmetry_mean	Rata-rata tingkat simetri sel
11	fractal_dimension_mean	Rata-rata dimensi fraktal sel
12	radius_se	Standar error dari radius
13	texture_se	Standar error dari tekstur
14	perimeter_se	Standar error dari perimeter
15	area_se	Standar error dari area

No	Variabel	Deskripsi
16	smoothness_se	Standar error dari smoothness
17	compactness_se	Standar error dari compactness
18	concavity_se	Standar error dari concavity
19	concave points_se	Standar error dari concave points
20	symmetry_se	Standar error dari symmetry
21	fractal_dimension_se	Standar error dari fractal dimension
22	radius_worst	Nilai radius terburuk atau terbesar yang diamati
23	texture_worst	Nilai tekstur terburuk atau tertinggi yang diamati
24	perimeter_worst	Nilai perimeter terburuk atau terbesar yang diamati
25	area_worst	Nilai area terburuk atau terbesar yang diamati
26	smoothness_worst	Nilai smoothness terburuk yang diamati
27	compactness_worst	Nilai compactness terburuk yang diamati
28	concavity_worst	Nilai concavity terburuk yang diamati
29	concave points_worst	Nilai concave points terburuk yang diamati
30	symmetry_worst	Nilai symmetry terburuk yang diamati

3. Metodologi

3.1 Import Library

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix
```

Tahap awal adalah mengimpor library yang dibutuhkan. Library pandas digunakan untuk membaca dan mengelola dataset, scikit-learn digunakan untuk proses pembagian data, standardisasi, pembuatan model KNN, dan evaluasi model, sedangkan matplotlib digunakan untuk menampilkan grafik perbandingan nilai K.

3.2 Membaca Dataset

```
df = pd.read_excel(r"C:\Users\THINKPAD\data_breastcancer.xlsx")
print("Data awal:")
print(df.head())

print("\nKolom dataset:")
print(df.columns)
```

Dataset dibaca menggunakan pd.read_excel(). Setelah itu dilakukan pengecekan data awal dengan head() untuk melihat beberapa baris pertama, serta columns untuk memastikan nama kolom sesuai. Langkah ini penting agar peneliti mengetahui struktur data sebelum masuk ke tahap preprocessing.

3.3 Preprocessing Data

```
if 'id' in df.columns:
    kolom_dihapus.append('id')

if 'Unnamed: 32' in df.columns:
    kolom_dihapus.append('Unnamed: 32')

df = df.drop(columns=kolom_dihapus, errors='ignore')

df['diagnosis'] = df['diagnosis'].map({'M': 1, 'B': 0})
```

Kolom id tidak digunakan karena tidak memiliki pengaruh terhadap hasil prediksi. Apabila terdapat kolom kosong seperti Unnamed: 32, kolom tersebut juga dihapus. Selanjutnya, nilai diagnosis diubah menjadi numerik, yaitu M = 1 dan B = 0, agar dapat diproses oleh algoritma KNN

3.4 Preprocessing Data

```
X = df.drop('diagnosis', axis=1)
y = df['diagnosis']
```

Variabel X berisi seluruh data numerik, sedangkan variabel y berisi target diagnosis. Pemisahan ini diperlukan agar model dapat belajar dari fitur untuk memprediksi target.

3.5 Pembagian Data Training dan Testing

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)
```

Data training digunakan untuk melatih model, sedangkan data testing digunakan untuk menguji performa model. Test_size=0.2 berarti 20% data dipakai untuk pengujian. Penggunaan random_state=42 bertujuan agar hasil pembagian data tetap konsisten, sedangkan stratify=y digunakan untuk proporsi kelas pada data training dan testing tetap seimbang.

3.6 Standarisasi Data

```
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)
```

Standardisasi dilakukan supaya semua fitur memiliki skala yang seimbang, sehingga tidak ada fitur yang terlalu dominan saat menghitung jarak. Proses fit_transform() dilakukan pada data training, sedangkan data testing hanya menggunakan transform() dengan skala yang sama. Hal ini dilakukan agar hasil pengujian tetap adil dan model tidak mendapat informasi dari data testing lebih awal.

3.7 Pembuatan dan Pelatihan Model KNN

```
knn = KNeighborsClassifier(n_neighbors=5)
knn.fit(X_train, y_train)
```

Pada tahap awal, model dibangun dengan nilai K = 5. Nilai K menunjukkan jumlah tetangga terdekat yang dijadikan dasar pengambilan keputusan klasifikasi. Proses fit() digunakan untuk melatih model berdasarkan pola yang ada pada data training.

3.8 Pengujian Model

```
y_pred = knn.predict(X_test)
```

Kode ini digunakan untuk menghasilkan prediksi kelas pada data testing. Hasil prediksi idigunakan untuk dibandingkan dengan data aktual untuk mengetahui performa model.

4. Hasil dan Pembahasan

4.1 Akurasi Model

Setelah proses preprocessing, pembagian data, standardisasi, training, dan testing dilakukan, model K-Nearest Neighbor (KNN) berhasil menghasilkan nilai akuras

Akurasi = 94,74%

Nilai akurasi ini menunjukkan bahwa model mampu memprediksi kelas data dengan cukup baik. Dari seluruh data testing, sekitar 94,74% data berhasil diklasifikasikan dengan benar ke dalam kategori benign atau malignant. Tingginya nilai akurasi menandakan bahwa pola antar data pada dataset ini dapat dikenali dengan baik oleh model. Dengan demikian, KNN dapat digunakan sebagai salah satu metode klasifikasi untuk membantu membedakan tumor jinak dan tumor ganas berdasarkan karakteristik data yang dimiliki.

4.2 Confusion Matrix

Confusion matrix digunakan untuk melihat jumlah prediksi benar dan prediksi salah pada masing-masing kelas. Dengan confusion matrix, performa model dapat dianalisis lebih rinci, sehingga dapat diketahui data mana yang berhasil diklasifikasikan dengan benar dan data mana yang masih mengalami kesalahan klasifikasi

[71 1]
[5 37]

Hasil tersebut menunjukkan bahwa model berhasil mengklasifikasikan 71 data benign dengan benar sebagai benign dan 37 data malignant dengan benar sebagai malignant. Namun, masih terdapat kesalahan klasifikasi, yaitu 1 data benign yang salah diprediksi sebagai malignant dan 5 data malignant yang salah diprediksi sebagai benign. Secara umum, confusion matrix ini menunjukkan bahwa model KNN memiliki performa yang baik dalam membedakan dua kelas pada dataset Breast Cancer

4.3 Classification Report

Classification Report:

	precision	recall	f1-score	support
0	0.93	0.99	0.96	72
1	0.97	0.88	0.93	42
accuracy			0.95	114
macro avg	0.95	0.93	0.94	114
weighted avg	0.95	0.95	0.95	114

recall Benign (0) sebesar 0,93 menunjukkan bahwa hampir seluruh data benign berhasil dikenali dengan benar oleh model. Hal ini berarti model cukup baik dalam mengenali sampel yang termasuk kategori jinak. sedangkan benign(1) dengan nilai precision yang tinggi menunjukkan bahwa saat model memprediksi suatu data sebagai malignant, hasil prediksi tersebut sebagian besar benar. Namun, nilai recall sebesar 0,88 menunjukkan bahwa masih ada beberapa data malignant yang belum berhasil dikenali oleh model. Hal ini sejalan dengan hasil confusion matrix yang menunjukkan adanya 5 data malignant yang salah diprediksi sebagai benign

4.4. Pengujian Nilai K

Untuk mengetahui nilai K yang paling baik, dilakukan pengujian terhadap beberapa nilai K, yaitu dari K = 1 sampai K = 20. Hasil pengujian menunjukkan bahwa setiap nilai K menghasilkan tingkat akurasi yang berbeda.

```
K = 1, Akurasi = 0.9561
K = 2, Akurasi = 0.9386
K = 3, Akurasi = 0.9561
K = 4, Akurasi = 0.9386
K = 5, Akurasi = 0.9474
K = 6, Akurasi = 0.9474
K = 7, Akurasi = 0.9474
K = 8, Akurasi = 0.9474
K = 9, Akurasi = 0.9474
K = 10, Akurasi = 0.9386
K = 11, Akurasi = 0.9386
K = 12, Akurasi = 0.9474
K = 13, Akurasi = 0.9386
K = 14, Akurasi = 0.9474
K = 15, Akurasi = 0.9386
K = 16, Akurasi = 0.9298
K = 17, Akurasi = 0.9298
K = 18, Akurasi = 0.9386
K = 19, Akurasi = 0.9474
K = 20, Akurasi = 0.9386
```

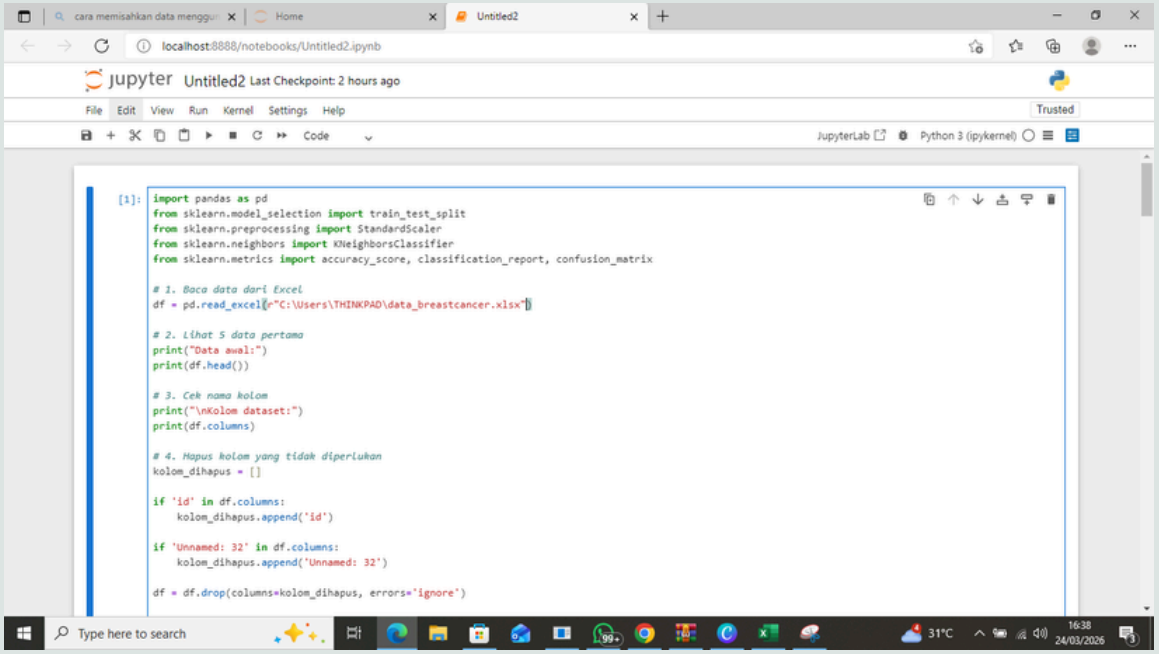
Berdasarkan hasil yang diperoleh, akurasi tertinggi sebesar 0,9561 atau 95,61% pada K = 1 dan K = 3. Sementara itu, beberapa nilai K lain seperti K = 5, 6, 7, 8, 9, 12, 14, dan 19 menghasilkan akurasi sebesar 0,9474 atau 94,74%. Nilai akurasi terendah pada pengujian ini adalah 0,9298 atau 92,98%, yaitu pada K = 16 dan K = 17. Hasil ini menunjukkan bahwa pemilihan nilai K berpengaruh terhadap performa model KNN. Semakin tepat nilai K yang dipilih, maka semakin baik pula hasil klasifikasi yang diperoleh. Dari grafik perbandingan nilai K dan akurasi, terlihat bahwa akurasi model cenderung stabil pada kisaran 0,93 sampai 0,95, sehingga model dapat dikatakan cukup konsisten.

5. **Kesimpulan**

Berdasarkan hasil pengujian dan pembahasan, dapat disimpulkan bahwa algoritma K-Nearest Neighbor berhasil diterapkan dengan baik pada dataset Breast Cancer Wisconsin. Model awal dengan K = 5 menghasilkan akurasi sebesar 94,74%, sedangkan hasil terbaik diperoleh pada K = 1 dan K = 3 dengan akurasi sebesar 95,61%. Dari kedua nilai tersebut, K = 3 lebih direkomendasikan karena memberikan hasil yang baik sekaligus lebih stabil.Secara keseluruhan, model KNN mampu mengklasifikasikan data kanker payudara ke dalam kategori benign dan malignant dengan tingkat ketepatan yang tinggi.

Lampiran

Link Dataset:
https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data?utm_source=chatgpt.com



```
[1]: import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix

# 1. Baca data dari Excel
df = pd.read_excel(r"C:\Users\THINKPAD\data_breastcancer.xlsx")

# 2. Lihat 5 data pertama
print("Data awal:")
print(df.head())

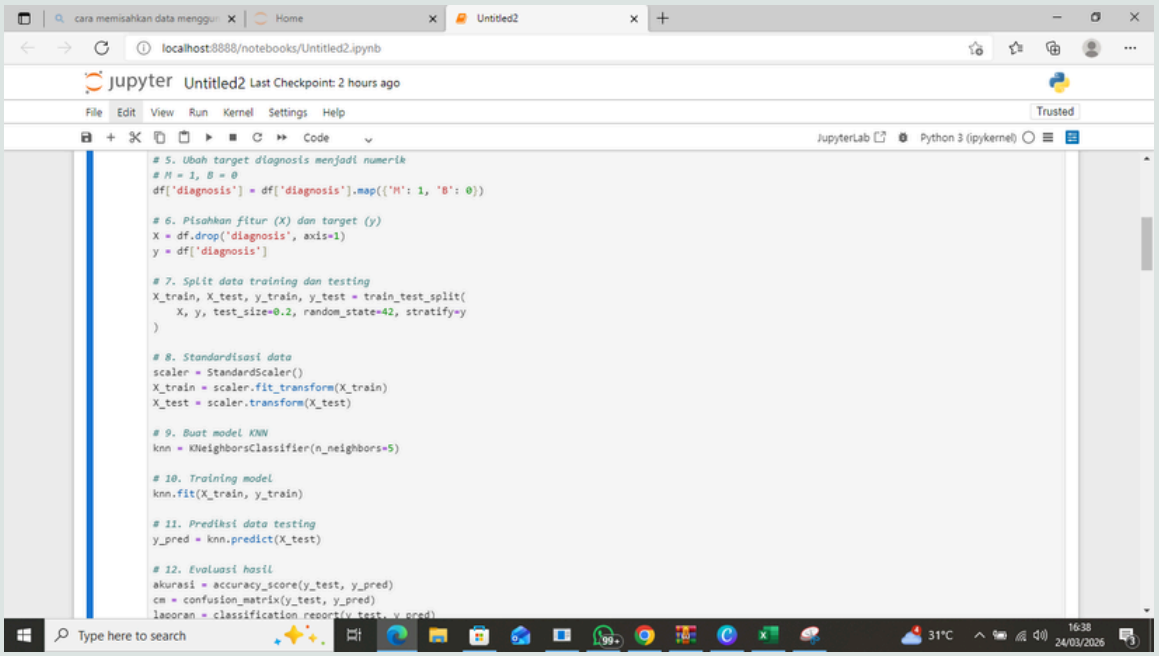
# 3. Cek nama kolom
print("\nKolom dataset:")
print(df.columns)

# 4. Hapus kolom yang tidak diperlukan
kolom_dihapus = []

if 'id' in df.columns:
    kolom_dihapus.append('id')

if 'Unnamed: 32' in df.columns:
    kolom_dihapus.append('Unnamed: 32')

df = df.drop(columns=kolom_dihapus, errors='ignore')
```



```
# 5. Ubah target diagnosis menjadi numerik
# M = 1, B = 0
df['diagnosis'] = df['diagnosis'].map({'M': 1, 'B': 0})

# 6. Pisahkan fitur (X) dan target (y)
X = df.drop('diagnosis', axis=1)
y = df['diagnosis']

# 7. Split data training dan testing
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

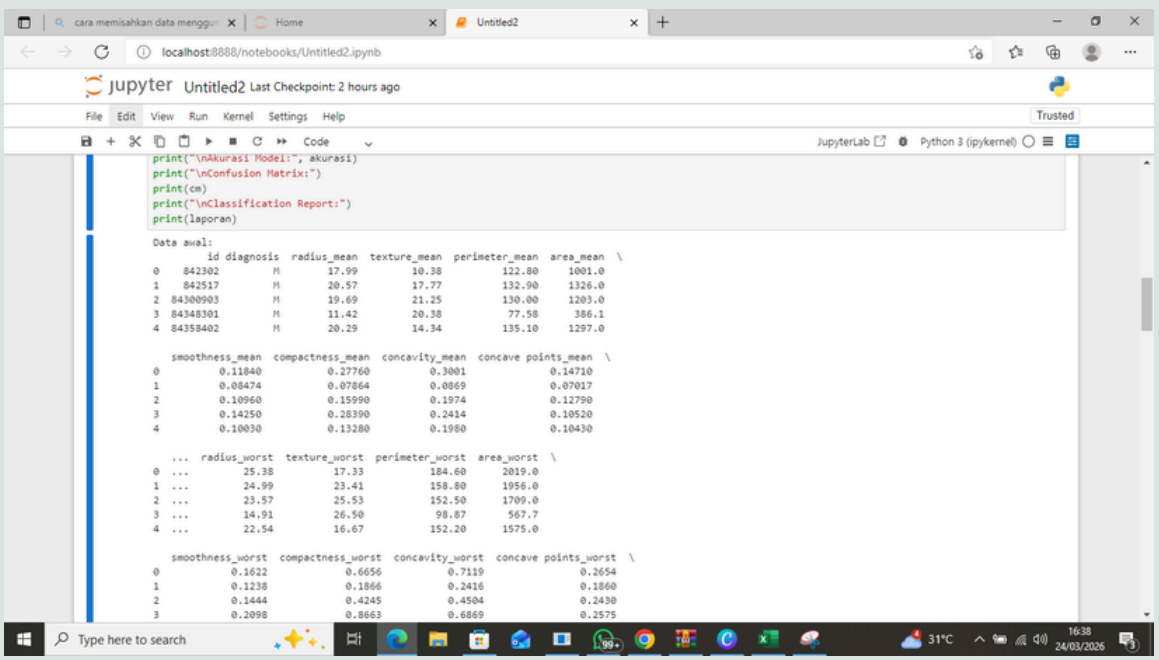
# 8. Standardisasi data
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

# 9. Buat model KNN
knn = KNeighborsClassifier(n_neighbors=5)

# 10. Training model
knn.fit(X_train, y_train)

# 11. Prediksi data testing
y_pred = knn.predict(X_test)

# 12. Evaluasi hasil
akurasi = accuracy_score(y_test, y_pred)
cm = confusion_matrix(y_test, y_pred)
laporan = classification_report(y_test, y_pred)
```



```
print("\nAkurasi Model:", akurasi)
print("\nConfusion Matrix:")
print(cm)
print("\nClassification Report:")
print(laporan)
```

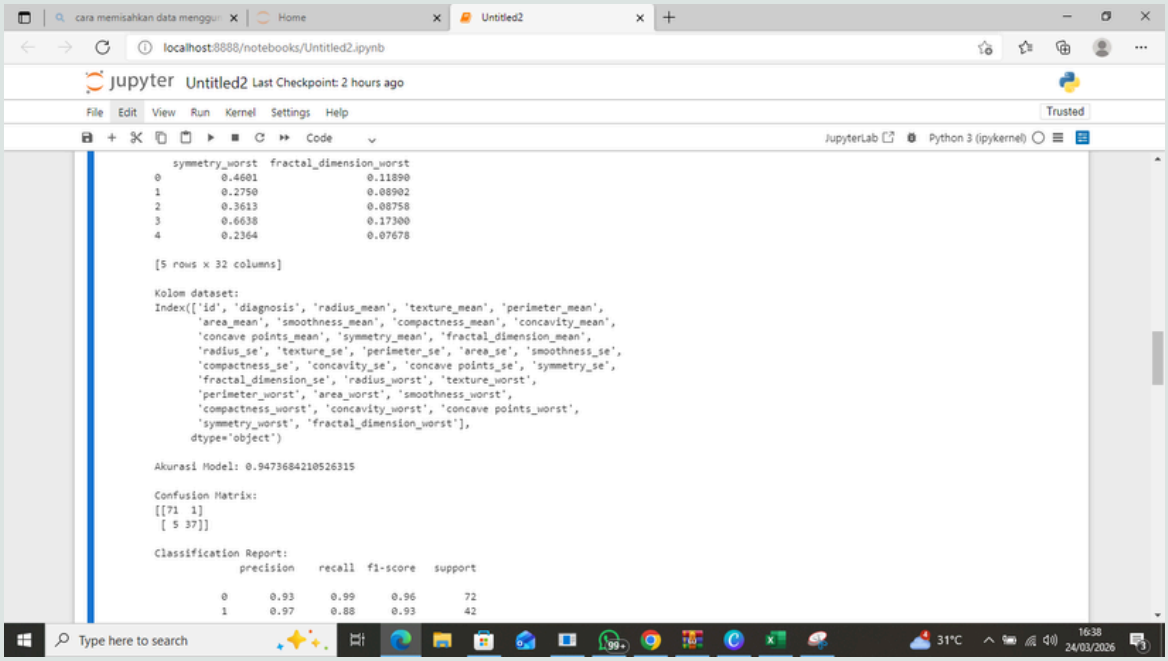
```
Data awal:
         id diagnosis  radius_mean  texture_mean  perimeter_mean  area_mean  \
0    842302         M        17.99         10.38          122.80     1001.0
1    842517         M        20.57         17.77          132.90     1326.0
2  84300903         M        19.69         21.25          130.00     1203.0
3  84348301         M        11.42         20.38           77.58      386.1
4  84358402         M        20.29         14.34          135.10     1297.0

   smoothness_mean  compactness_mean  concavity_mean  concave points_mean  \
0          0.11840           0.27760          0.3001              0.14710
1          0.08474           0.07864          0.0869              0.07017
2          0.10960           0.15990          0.1974              0.12790
3          0.14250           0.28390          0.2414              0.10520
4          0.10030           0.13280          0.1980              0.10430

   ...  radius_worst  texture_worst  perimeter_worst  area_worst  \
0  ...         25.38          17.33           184.60      2019.0
1  ...         24.99          23.41           158.80      1956.0
2  ...         23.57          25.53           152.50      1709.0
3  ...         14.91          26.50            98.87       567.7
4  ...         22.54          16.67           152.20      1575.0

   smoothness_worst  compactness_worst  concavity_worst  concave points_worst  \
0            0.1622             0.6656           0.7119                0.2654
1            0.1238             0.1866           0.2416                0.1860
2            0.1444             0.4245           0.4504                0.2430
3            0.2098             0.8663           0.6869                0.2575
```

Lampiran



```
   symmetry_worst  fractal_dimension_worst
0          0.4601                  0.11890
1          0.2750                  0.08902
2          0.3613                  0.08758
3          0.6638                  0.17300
4          0.2364                  0.07678

[5 rows x 32 columns]

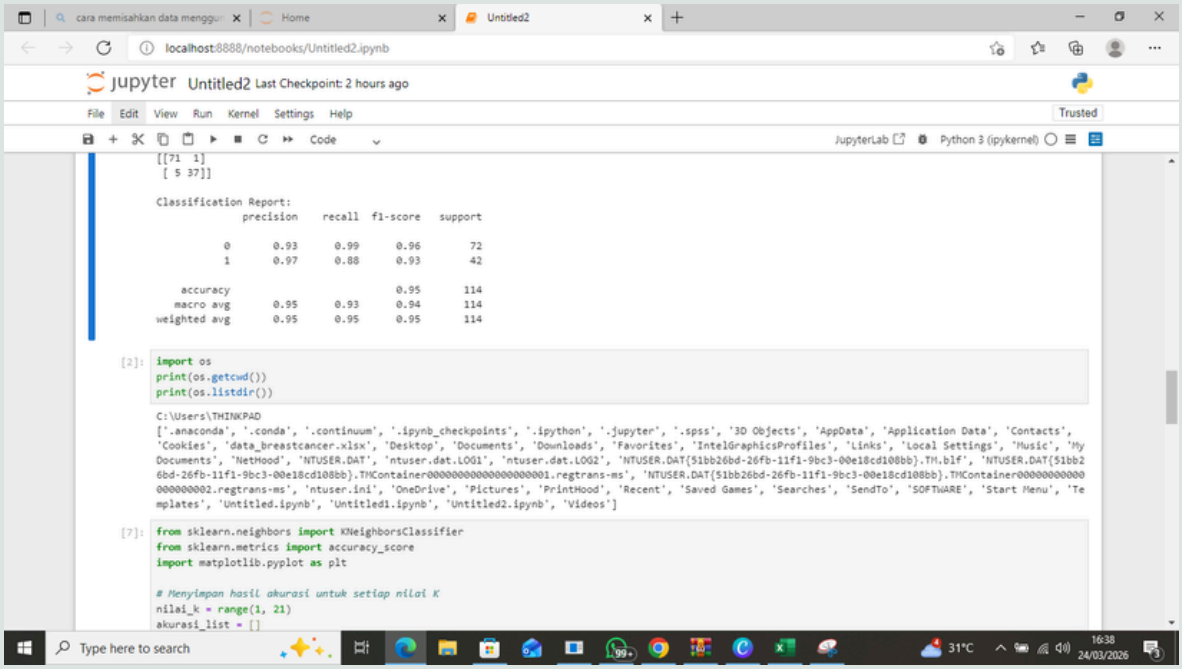
Kolom dataset:
Index(['id', 'diagnosis', 'radius_mean', 'texture_mean', 'perimeter_mean',
       'area_mean', 'smoothness_mean', 'compactness_mean', 'concavity_mean',
       'concave points_mean', 'symmetry_mean', 'fractal_dimension_mean',
       'radius_se', 'texture_se', 'perimeter_se', 'area_se', 'smoothness_se',
       'compactness_se', 'concavity_se', 'concave points_se', 'symmetry_se',
       'fractal_dimension_se', 'radius_worst', 'texture_worst',
       'perimeter_worst', 'area_worst', 'smoothness_worst',
       'compactness_worst', 'concavity_worst', 'concave points_worst',
       'symmetry_worst', 'fractal_dimension_worst'],
      dtype='object')

Akurasi Model: 0.9473684210526315

Confusion Matrix:
[[71  1]
 [ 5 37]]

Classification Report:
              precision    recall  f1-score   support

           0       0.93      0.99      0.96        72
           1       0.97      0.88      0.93        42
```



```
[[71  1]
 [ 5 37]]

Classification Report:
              precision    recall  f1-score   support

           0       0.93      0.99      0.96        72
           1       0.97      0.88      0.93        42

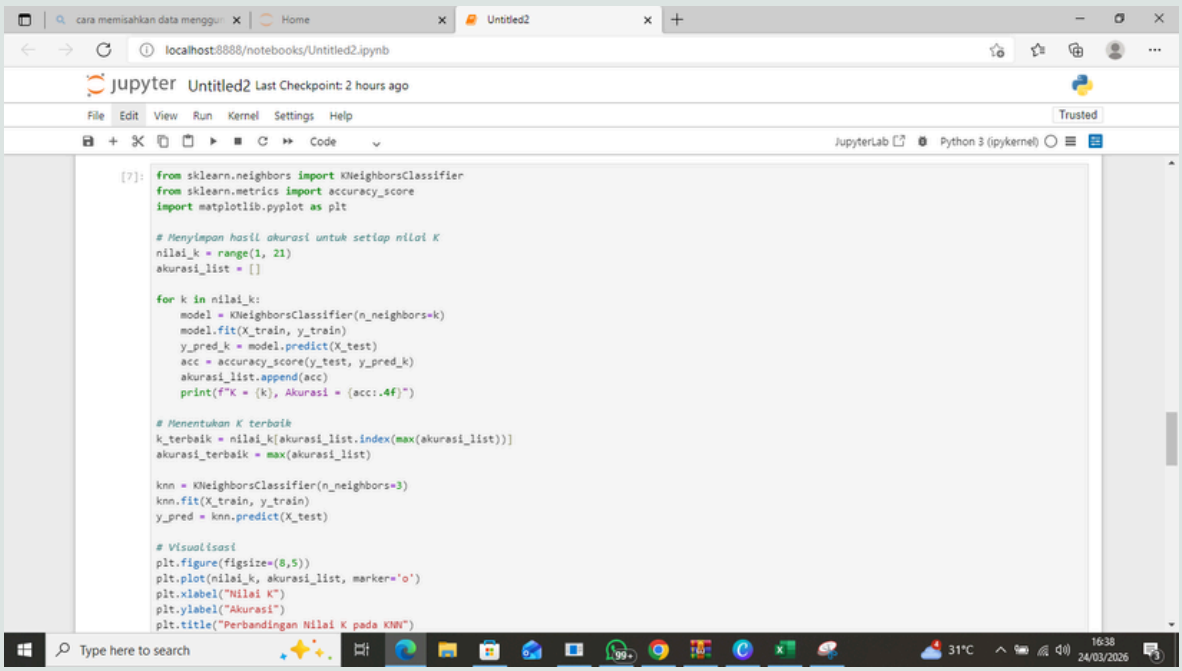
    accuracy                           0.95       114
   macro avg       0.95      0.93      0.94       114
weighted avg       0.95      0.95      0.95       114
```

```
[2]: import os
     print(os.getcwd())
     print(os.listdir())
```

```
C:\Users\THINKPAD
['.anaconda', '.conda', '.continuum', '.ipynb_checkpoints', '.ipython', '.jupyter', '.spss', '3D Objects', 'AppData', 'Application Data', 'Contacts',
'Cookies', 'data_breastcancer.xlsx', 'Desktop', 'Documents', 'Downloads', 'Favorites', 'IntelGraphicsProfiles', 'Links', 'Local Settings', 'Music', 'My
Documents', 'NetHood', 'NTUSER.DAT', 'ntuser.dat.LOG1', 'ntuser.dat.LOG2', 'NTUSER.DAT{51bb26bd-26fb-11f1-9bc3-00e18cd108bb}.TM.blf', 'NTUSER.DAT{51bb2
6bd-26fb-11f1-9bc3-00e18cd108bb}.TMContainer00000000000000000001.regtrans-ms', 'NTUSER.DAT{51bb26bd-26fb-11f1-9bc3-00e18cd108bb}.TMContainer00000000000
00000002.regtrans-ms', 'ntuser.ini', 'OneDrive', 'Pictures', 'PrintHood', 'Recent', 'Saved Games', 'Searches', 'SendTo', 'SOFTWARE', 'Start Menu', 'Te
mplates', 'Untitled.ipynb', 'Untitled1.ipynb', 'Untitled2.ipynb', 'Videos']
```

```
[7]: from sklearn.neighbors import KNeighborsClassifier
     from sklearn.metrics import accuracy_score
     import matplotlib.pyplot as plt

     # Menyimpan hasil akurasi untuk setiap nilai K
     nilai_k = range(1, 21)
     akurasi_list = []
```



```
[7]: from sklearn.neighbors import KNeighborsClassifier
     from sklearn.metrics import accuracy_score
     import matplotlib.pyplot as plt

     # Menyimpan hasil akurasi untuk setiap nilai K
     nilai_k = range(1, 21)
     akurasi_list = []

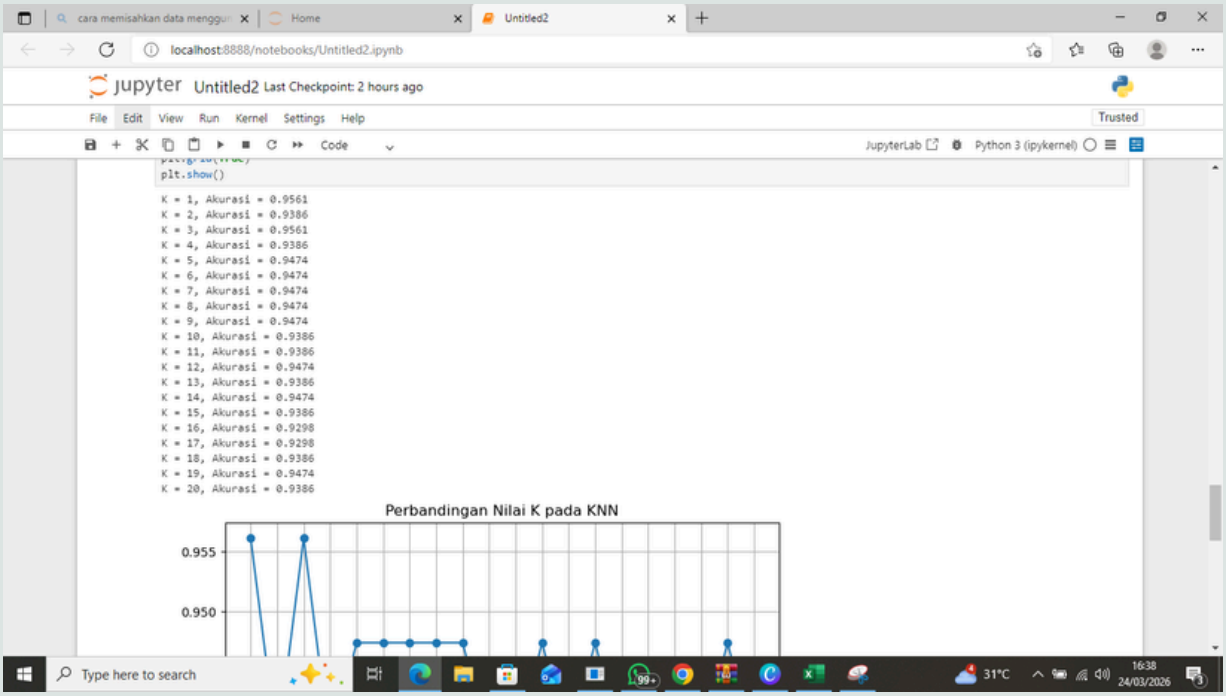
     for k in nilai_k:
         model = KNeighborsClassifier(n_neighbors=k)
         model.fit(X_train, y_train)
         y_pred_k = model.predict(X_test)
         acc = accuracy_score(y_test, y_pred_k)
         akurasi_list.append(acc)
         print(f"K = {k}, Akurasi = {acc:.4f}")

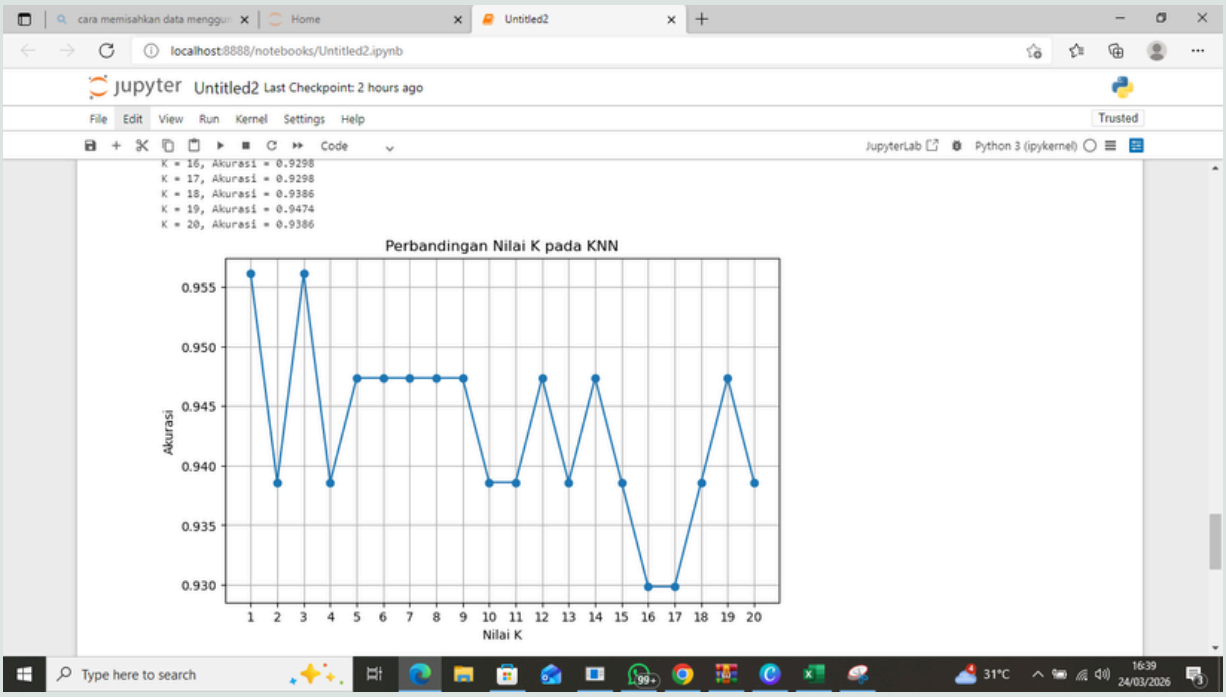
     # Menentukan K terbaik
     k_terbaik = nilai_k[akurasi_list.index(max(akurasi_list))]
     akurasi_terbaik = max(akurasi_list)

     knn = KNeighborsClassifier(n_neighbors=3)
     knn.fit(X_train, y_train)
     y_pred = knn.predict(X_test)

     # Visualisasi
     plt.figure(figsize=(8,5))
     plt.plot(nilai_k, akurasi_list, marker='o')
     plt.xlabel("Nilai K")
     plt.ylabel("Akurasi")
     plt.title("Perbandingan Nilai K pada KNN")
```

Lampiran


localhost:8888/notebooks/Untitled2.ipynb
jupyter Untitled2 Last Checkpoint: 2 hours ago
File Edit View Run Kernel Settings Help
Trusted
Code
JupyterLab
Python 3 (ipykernel)
plt.show()
K = 1, Akurasi = 0.9561
K = 2, Akurasi = 0.9386
K = 3, Akurasi = 0.9561
K = 4, Akurasi = 0.9386
K = 5, Akurasi = 0.9474
K = 6, Akurasi = 0.9474
K = 7, Akurasi = 0.9474
K = 8, Akurasi = 0.9474
K = 9, Akurasi = 0.9474
K = 10, Akurasi = 0.9386
K = 11, Akurasi = 0.9386
K = 12, Akurasi = 0.9474
K = 13, Akurasi = 0.9386
K = 14, Akurasi = 0.9474
K = 15, Akurasi = 0.9386
K = 16, Akurasi = 0.9298
K = 17, Akurasi = 0.9298
K = 18, Akurasi = 0.9386
K = 19, Akurasi = 0.9474
K = 20, Akurasi = 0.9386
Perbandingan Nilai K pada KNN
0.955
0.950
Type here to search
31°C
16:38
24/03/2026


localhost:8888/notebooks/Untitled2.ipynb
jupyter Untitled2 Last Checkpoint: 2 hours ago
File Edit View Run Kernel Settings Help
Trusted
Code
JupyterLab
Python 3 (ipykernel)
K = 16, Akurasi = 0.9298
K = 17, Akurasi = 0.9298
K = 18, Akurasi = 0.9386
K = 19, Akurasi = 0.9474
K = 20, Akurasi = 0.9386
Perbandingan Nilai K pada KNN
Akurasi
0.955
0.950
0.945
0.940
0.935
0.930
1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20
Nilai K
Type here to search
31°C
16:39
24/03/2026