Prediksi Pergerakan Kurs Rupiah Terhadap Dolar Amerika Serikat (USD/IDR) Menggunakan LSTM, GRU, dan CNN

Sabrina Syafa[1], Muhammad Bintang Anugerah[2], Candra Savira[3], Jalu Ramdhana Dielizal[4], Hanif Wibowo [5]
Robi Ardana Putra S.Tr.Stat, Noviyanti Santoso, S.Si, M.Si, Ph.D
e-mail: muhammadbintang397@gmail.com

Abstrak*— Nilai tukar Rupiah terhadap Dolar Amerika Serikat (USD/IDR) merupakan indikator ekonomi yang memiliki peran penting dalam stabilitas perekonomian nasional. Tingginya volatilitas kurs menyebabkan proses peramalan menjadi semakin kompleks sehingga diperlukan metode yang mampu menangkap pola nonlinier dan dinamika data deret waktu. Penelitian ini bertujuan membandingkan kinerja metode *Long Short-Term Memory* (LSTM), *Gated Recurrent Unit* (GRU), dan *Convolutional Neural Network* (CNN) dalam memprediksi volatilitas kurs USD/IDR serta mengembangkan *dashboard* interaktif untuk visualisasi hasil prediksi. Data yang digunakan merupakan data harian kurs USD/IDR periode 6 Juni 2016 hingga 5 Juni 2026 yang diperoleh dari Investing.com. Volatilitas dihitung menggunakan metode *squared return*, kemudian dilakukan proses normalisasi dan pembentukan sekuens data. Pemilihan hyperparameter dilakukan menggunakan *Random Search* dengan skema *Sliding Window Cross-Validation* sebanyak empat kelompok data. Evaluasi model dilakukan menggunakan *Root Mean Square Error* (RMSE) dan persentase nilai aktual yang berada dalam selang kepercayaan 95%. Hasil penelitian menunjukkan bahwa ketiga model mampu memprediksi volatilitas dengan baik dan menghasilkan nilai RMSE yang relatif serupa. Berdasarkan kombinasi nilai RMSE dan selang kepercayaan, model GRU ditetapkan sebagai model terbaik karena menunjukkan keseimbangan antara akurasi dan konsistensi prediksi. Model terbaik kemudian digunakan untuk melakukan peramalan volatilitas selama 30 hari ke depan dan hasilnya diintegrasikan ke dalam *dashboard* Streamlit untuk memudahkan proses pemantauan dan interpretasi hasil prediksi.

Kata Kunci*— CNN, Deep Learning, GRU, LSTM, Random Search, Streamlit, USD/IDR, Volatilitas Kurs.

I. PENDAHULUAN

Nilai tukar rupiah terhadap dolar Amerika Serikat (USD/IDR) merupakan salah satu indikator makroekonomi paling krusial bagi perekonomian Indonesia. Fluktuasi nilai tukar dapat memengaruhi inflasi, harga barang impor, dan daya saing ekspor. Di Indonesia, depresiasi rupiah terhadap dolar Amerika Serikat sering diikuti dengan kenaikan tingkat inflasi yang berdampak luas pada perekonomian secara keseluruhan [1]. Pada pertengahan Juni 2026, mata uang Garuda ditutup melemah 0,17% ke level Rp17.980/US$. Pelemahan rupiah terjadi seiring dengan menguatnya dolar AS di pasar global. Penguatan greenback membuat ruang penguatan mata uang negara lain, termasuk rupiah, menjadi semakin terbatas [2]. Prediksi nilai tukar menjadi kompleks karena dipengaruhi banyak faktor, antara lain perbedaan tingkat suku bunga, defisit transaksi berjalan, utang publik, harga komoditas, stabilitas politik, serta peristiwa tak terduga seperti pandemi, bencana alam, dan gejolak geopolitik [1]. Mengingat dampaknya yang luas terhadap stabilitas ekonomi, investasi, dan perdagangan internasional, kemampuan memprediksi pergerakan kurs secara akurat menjadi kebutuhan yang nyata.

Pergerakan kurs merupakan data deret waktu (*time series*) yang bersifat nonlinier, tidak stasioner, dan mengandung volatilitas yang dinamis. Metode statistik konvensional seperti ARIMA yang didasarkan pada asumsi homoskedastisitas memiliki keterbatasan mendasar dalam kondisi ini; ketika volatilitas tinggi terjadi, ARIMA tidak mampu menangani fluktuasi tersebut sehingga hasil peramalannya menjadi kurang akurat [3]. Sebagai respons atas keterbatasan tersebut, penelitian ini menggunakan pendekatan *deep learning* yang terbukti mampu menangkap pola-pola tersembunyi dalam data yang tidak bisa ditangkap oleh model peramalan konvensional [3]. Arsitektur pertama yang digunakan adalah *Long Short-Term Memory* (LSTM), sebuah jenis *Recurrent Neural Network* yang dirancang khusus untuk mengatasi masalah *vanishing gradient* melalui mekanisme tiga gerbang (*forget*, *input*, dan *output gate*) yang memungkinkan jaringan mempertahankan informasi dari periode sebelumnya dalam rentang panjang [1]. Kemampuan ini menjadikan LSTM unggul dalam menangkap pola nonlinier dan fluktuasi jangka panjang pada data kurs, sebagaimana ditunjukkan dalam penelitian Septani et al. (2025) yang mendapatkan nilai RMSE terkecil pada data *testing* untuk LSTM dibanding metode lain yang diujikan.

Arsitektur kedua yang digunakan adalah *Gated Recurrent Unit* (GRU), yang merupakan versi lebih sederhana dan efisien dari LSTM namun tetap mampu menangkap pola penting dalam data deret waktu [3]. GRU menggabungkan *forget gate* dan *input gate* LSTM menjadi satu *update gate* sehingga memiliki lebih sedikit parameter, yang berarti proses pelatihan lebih ringan secara komputasi. Dari sisi kinerja empiris pada data kurs USD/IDR, GRU menunjukkan hasil yang menonjol. Dalam penelitian Septani et al. (2025) yang menggunakan data harian kurs rupiah periode Januari 2015 hingga Maret 2024, GRU mencatat persentase nilai aktual dalam selang kepercayaan 95% tertinggi sebesar 92,39% pada data *testing*, mengungguli LSTM, GARCH, maupun CNN, sehingga disimpulkan sebagai metode terbaik karena mampu memberikan keseimbangan optimal antara akurasi prediksi dan konsistensi. Temuan serupa juga ditemukan pada data saham sektor telekomunikasi Indonesia, di mana GRU terbukti lebih adaptif pada pola harga yang dinamis dan berfluktuasi tinggi [4].

Arsitektur ketiga yang digunakan adalah *Convolutional Neural Network* (CNN), yang umumnya dikenal untuk pengenalan gambar namun juga dapat diterapkan dalam analisis data deret waktu. CNN memiliki kemampuan mengekstrak fitur-fitur penting dari data sekuensial dengan menggunakan filter konvolusional. Ketika diterapkan pada analisis volatilitas, CNN dapat membantu menangkap pola lokal yang signifikan dalam fluktuasi harga yang mungkin terlewat oleh model lain [3]. Meski dalam beberapa studi CNN menunjukkan performa lebih rendah dibanding LSTM dan GRU pada data kurs [3], kehadiran CNN dalam penelitian ini tetap relevan untuk mengevaluasi kemampuannya mengekstrak pola lokal jangka pendek yang berpotensi melengkapi kelemahan arsitektur berbasis RNN. Evaluasi performa ketiga model akan dilakukan menggunakan metrik standar *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), dan *Mean Absolute Percentage Error* (MAPE), yang memungkinkan perbandingan objektif antar arsitektur [4].

Sejumlah penelitian terdahulu telah mengkaji prediksi volatilitas kurs menggunakan berbagai pendekatan machine learning. Septani et al. (2025) membandingkan metode GARCH, LSTM, GRU, dan CNN dalam peramalan volatilitas kurs USD/IDR dan menemukan bahwa GRU memberikan performa prediksi terbaik dibandingkan metode lainnya. Penelitian Andromeda dan Winarsih (2025) juga menunjukkan keunggulan GRU dibandingkan LSTM dalam memprediksi aset dengan tingkat volatilitas tinggi, meskipun objek yang diteliti adalah cryptocurrency. Sementara itu, Kevin et al. (2025) mengembangkan model hybrid LSTM-XGBoost untuk prediksi kurs USD/IDR dengan memasukkan variabel makroekonomi sebagai faktor penjelas dan memperoleh peningkatan akurasi dibandingkan model tunggal. Meskipun berbagai penelitian tersebut telah berhasil meningkatkan performa prediksi, fokus penelitian masih terbatas pada pengembangan dan evaluasi model prediksi. Belum banyak penelitian yang mengintegrasikan hasil prediksi ke dalam sebuah dashboard interaktif yang dapat mendukung pemantauan, interpretasi, dan pemanfaatan hasil prediksi secara lebih praktis oleh pengguna. Oleh karena itu, penelitian ini tidak hanya membangun model prediksi volatilitas kurs menggunakan pendekatan machine learning, tetapi juga mengembangkan dashboard visualisasi yang memungkinkan pengguna mengakses dan menganalisis hasil prediksi secara lebih mudah dan informatif.

II. URAIAN PENELITIAN

A. Penelitian Terdahulu

Penelitian oleh Kevin, Iskandar, dan Tendean yang berjudul "Model *Hybrid* LSTM-XGBoost untuk Prediksi Nilai Tukar Rupiah terhadap Dolar Amerika" mengusulkan kombinasi metode LSTM dan XGBoost untuk meningkatkan akurasi prediksi nilai tukar Rupiah terhadap Dolar Amerika. Hasil penelitian menunjukkan bahwa model hibrid memberikan performa yang lebih baik dibandingkan model tunggal. Persamaan dengan penelitian ini terletak pada penggunaan metode *deep learning* untuk prediksi kurs, sedangkan perbedaannya adalah penggunaan model hibrid dan variabel makroekonomi sebagai prediktor [1].

Andromeda dan Winarsih dalam penelitian "Perbandingan Kinerja Metode LSTM dan GRU dalam Prediksi Harga *Close Cryptocurrency*" membandingkan metode LSTM dan GRU untuk memprediksi harga Bitcoin dan Ethereum. Hasil penelitian menunjukkan bahwa GRU memiliki performa yang lebih baik dibandingkan LSTM berdasarkan nilai MAPE, RMSE, dan R^2. Persamaan penelitian ini adalah penggunaan metode LSTM dan GRU pada data deret waktu, sedangkan perbedaannya terletak pada objek penelitian yang berfokus pada *cryptocurrency* [5].

Penelitian oleh Septani, Afendi, dan Kurnia berjudul "Perbandingan Metode GARCH, LSTM, GRU, dan CNN pada Peramalan Volatilitas Kurs" membandingkan empat metode dalam memprediksi volatilitas kurs Rupiah terhadap Dolar Amerika. Hasil penelitian menunjukkan bahwa GRU memberikan kinerja terbaik dalam menyeimbangkan akurasi dan konsistensi prediksi. Persamaan dengan penelitian ini terletak pada penggunaan metode *deep learning* untuk analisis kurs, sedangkan perbedaannya adalah fokus penelitian terdahulu pada volatilitas kurs, bukan prediksi nilai tukar [3].

B. Data Deret Waktu (Time Series)

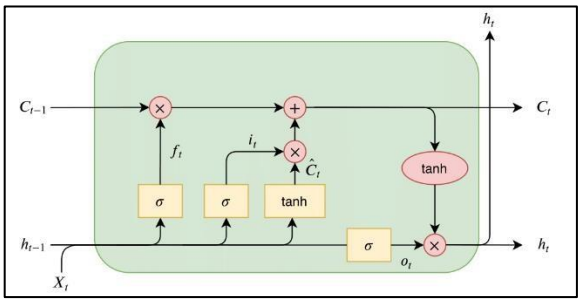
Data deret waktu (*time series*) adalah sekumpulan data yang dikumpulkan dan dicatat secara berurutan berdasarkan waktu tertentu, seperti harian, mingguan, bulanan, atau tahunan [6]. Data deret waktu memiliki karakteristik utama berupa adanya keterkaitan antara nilai pengamatan saat ini dengan nilai pada periode sebelumnya. Oleh karena itu, analisis data deret waktu digunakan untuk mengidentifikasi pola, tren, dan perubahan yang terjadi dari waktu ke waktu serta melakukan peramalan nilai pada periode mendatang.

C. Machine Learning dan Deep Learning

Machine Learning merupakan cabang dari *Artificial Intelligence* yang memungkinkan komputer mempelajari pola dari data untuk melakukan prediksi atau pengambilan keputusan tanpa diprogram secara eksplisit [7]. Seiring berkembangnya kebutuhan untuk mengolah data yang semakin kompleks dan berukuran besar, muncul *Deep Learning* sebagai pengembangan dari *machine learning* yang memanfaatkan jaringan saraf tiruan dengan banyak lapisan (*deep neural networks*) untuk secara otomatis mengekstraksi fitur dan mempelajari pola yang lebih kompleks [8]. Dengan kemampuannya tersebut, *deep learning* banyak digunakan dalam berbagai aplikasi seperti pengolahan teks, pengenalan gambar, dan prediksi perilaku pengguna.

D. Metode LSTM (Long Short-Term Memory)

Long Short-Term Memory (LSTM) merupakan salah satu pengembangan dari metode *Recurrent Neural Network* (RNN) yang dirancang untuk mengatasi masalah hilangnya informasi (*vanishing gradient*) pada data deret waktu. LSTM memiliki kemampuan untuk menyimpan dan mengingat informasi penting dalam jangka pendek maupun jangka panjang melalui mekanisme sel memori (*memory cell*) [9]. Kemampuan tersebut membuat LSTM efektif dalam menangkap pola dan hubungan temporal yang kompleks pada data berurutan, seperti nilai tukar mata uang, harga saham, dan data keuangan lainnya. LSTM banyak digunakan dalam tugas peramalan karena mampu menghasilkan prediksi yang akurat dan mendukung pengambilan keputusan yang lebih baik [10]. Arsitektur algoritma LSTM ditunjukkan pada Gambar 1 berikut.



Gambar 1. Arsitektur Algoritma LSTM
Sumber: www.projectpro.io

Adapun beberapa formula dalam LSTM dituliskan dalam Persamaan 1 hingga 6 berikut.

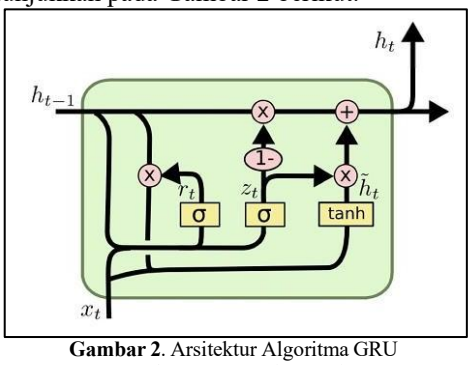
$$f_t = \sigma * (W_f[h_{t-1}, x_t] + b_f) \quad (1)$$
$$i_t = \sigma * (W_i[h_{t-1}, x_t] + b_i) \quad (2)$$
$$C_t = tanh(W_c[h_{t-1}, x_t] + b_c) \quad (3)$$
$$C_t = f_t * C_{t-1} + i_t * C_t \quad (4)$$
$$O_t = \sigma * (W_o[h_{t-1}, x_t] + b_o) \quad (5)$$
$$h_t = O_t * tanh(C_t) \quad (6)$$

Keterangan:

f_t	= *Forget gate*	W	= Bobot matriks
i_t	= *Input gate*	b	= Bias
O_t	= *Output gate*	σ	= Fungsi sigmoid
C_t	= *Cell state*	$tanh$	= Fungsi aktivasi
h_t	= *Hidden state*		

*E. Metode GRU (*Gated Recurrent Unit*)*

Gated Recurrent Unit (GRU) merupakan salah satu metode *deep learning* yang termasuk dalam arsitektur jaringan saraf berulang (*Recurrent Neural Network* atau RNN) dan dirancang untuk memproses data sekuensial, seperti teks, deret waktu, maupun data temporal lainnya. GRU menggunakan mekanisme *gating* berupa *update gate* dan *reset gate* untuk mengatur aliran informasi sehingga mampu mengatasi permasalahan *vanishing gradient* yang sering terjadi pada RNN konvensional [11]. Dibandingkan dengan metode *Long Short-Term Memory* (LSTM), GRU memiliki struktur yang lebih sederhana dengan jumlah parameter yang lebih sedikit, sehingga proses pelatihan menjadi lebih cepat namun tetap mampu mempertahankan informasi penting dari data historis. GRU banyak digunakan dalam tugas prediksi, analisis sentimen, pemrosesan bahasa alami, dan peramalan deret waktu [12]. Arsitektur algoritma GRU ditunjukkan pada Gambar 2 berikut.



Gambar 2. Arsitektur Algoritma GRU
Sumber: www.projectpro.io

Adapun beberapa formula dalam GRU dituliskan dalam Persamaan 7 hingga 10 berikut.

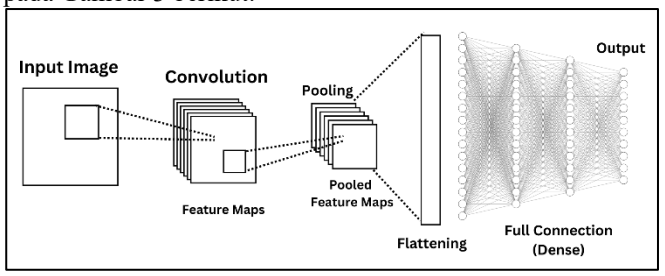
$$r_{(t)} = \sigma * (W_f . x_{(t)} + U_r h_{(t-1)} + b_r) \quad (7)$$
$$\tilde{h}_t = tanh(U_h [r_{(t)} * h_{(t-1)}] + W_h x_{(t)} + b_h) \quad (8)$$
$$z_{(t)} = \sigma * (W_z x_{(t)} + U_z h_{(t-1)} + b_z) \quad (9)$$
$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t \quad (10)$$

Keterangan:

r_t	= *Reset gate*	W	= Bobot matriks
z_t	= *Update gate*	b	= Bias
h_t	= *Hidden state*	σ	= Fungsi sigmoid
U	= *Bobot hidden state*	$tanh$	= Fungsi aktivasi

*F. Metode CNN (*Convolutional Neural Network*)*

Convolutional Neural Network (CNN) merupakan salah satu metode *deep learning* yang dirancang khusus untuk mengolah data berbentuk grid, terutama citra atau gambar. CNN bekerja dengan menggunakan operasi konvolusi (*convolution*) untuk mengekstraksi fitur-fitur penting secara otomatis dari data masukan, seperti tepi, tekstur, pola, hingga objek yang lebih kompleks [13]. Arsitektur CNN umumnya terdiri atas lapisan konvolusi (*convolution layer*), lapisan penggabungan (*pooling layer*), dan lapisan terhubung penuh (*fully connected layer*) yang bekerja secara bertahap untuk mempelajari representasi data dan melakukan proses klasifikasi atau prediksi. Kemampuannya dalam mengenali pola visual dengan tingkat akurasi yang tinggi menjadikan CNN banyak digunakan dalam berbagai aplikasi, seperti pengenalan wajah, klasifikasi gambar, deteksi objek, serta analisis video [14]. Arsitektur algoritma CNN ditunjukkan pada Gambar 3 berikut.



Gambar 3. Arsitektur Algoritma CNN
Sumber: quarkml.com

Adapun rumus perhitungan pada proses konvolusi tersebut ditunjukkan pada persamaan 11 berikut.

$$l_t = \tanh(x_t * k_t + b_t) \quad (11)$$

Keterangan:

l_t	= *Convolution output*	k_t	= Bobot konvolusi
x_t	= *Input vector*	b_t	= Bias

G. Evaluasi Kebaikan Model

Evaluasi kebaikan model dilakukan untuk mengukur seberapa baik model dalam menghasilkan prediksi yang akurat dan andal. Salah satu metrik yang umum digunakan adalah *Root Mean Square Error* (RMSE), yaitu ukuran kesalahan prediksi yang dihitung berdasarkan akar kuadrat dari rata-rata selisih kuadrat antara nilai aktual dan nilai prediksi [15]. Semakin kecil nilai RMSE, semakin baik kemampuan model dalam memprediksi data karena menunjukkan tingkat kesalahan yang rendah. Rumus perhitungan RMSE dituliskan dalam persamaan 12 berikut.

$$RMSE = \sqrt{\frac{\sum_{i=1}^{n} (Y_i - \hat{Y}_i)^2}{n}} \quad (12)$$

Keterangan:

n	= Jumlah data	$\hat{Y}_i$	= Nilai prediksi
Y_i	= Nilai aktual		

Selain itu, evaluasi juga dapat dilakukan menggunakan selang kepercayaan (*confidence interval*), yaitu rentang nilai yang diperkirakan mengandung parameter atau hasil prediksi sebenarnya pada tingkat keyakinan tertentu, misalnya 95%, sehingga memberikan gambaran mengenai ketidakpastian

prediksi model [3]. Rumus selang kepercayaan dituliskan pada persamaan 13 berikut.

$$SK(1-\alpha)\% = \bar{x} \pm Z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \quad (13)$$

Keterangan:
$\bar{x}$ = Rata-rata data σ = Simpangan baku populasi
$Z_{\alpha/2}$ = Nilai kritis n = Jumlah data

Kombinasi RMSE dan selang kepercayaan memberikan evaluasi yang lebih komprehensif, karena RMSE mengukur tingkat ketepatan prediksi model, sedangkan selang kepercayaan menggambarkan tingkat keandalan serta kestabilan hasil estimasi yang dihasilkan. Penggunaan selang kepercayaan menjadi penting karena dalam praktiknya model prediksi tidak hanya dituntut akurat, tetapi juga perlu menunjukkan seberapa pasti hasil tersebut dapat digeneralisasi pada data yang lebih luas [16]. Dengan adanya informasi ketidakpastian ini, peneliti dapat menilai risiko deviasi prediksi dan menghindari kesimpulan yang terlalu percaya diri terhadap hasil model. Oleh karena itu, validasi menggunakan selang kepercayaan menjadi krusial untuk memastikan bahwa performa model tidak hanya baik secara rata-rata (melalui RMSE), tetapi juga konsisten dan dapat diandalkan dalam berbagai kondisi data. Dengan demikian, model yang memiliki nilai RMSE rendah dan selang kepercayaan yang sempit umumnya dianggap memiliki performa yang lebih baik dalam melakukan prediksi.

H. Return

Return merupakan tingkat keuntungan atau kerugian yang diperoleh investor dari suatu investasi selama periode tertentu [17]. Return menunjukkan perubahan nilai investasi yang berasal dari kenaikan atau penurunan harga aset serta pendapatan tambahan, seperti dividen atau bunga. Dalam analisis keuangan dan pasar modal, return digunakan sebagai indikator utama untuk mengukur kinerja suatu aset atau portofolio investasi [18]. Semakin tinggi nilai return yang diperoleh, semakin besar keuntungan yang diterima investor, meskipun umumnya return yang lebih tinggi juga diikuti oleh tingkat risiko yang lebih besar. Analisis return menjadi dasar penting dalam pengambilan keputusan investasi dan pengukuran kinerja aset keuangan. Secara matematis, rumus perhitungan return dan volatilitas dapat dilihat pada persamaan 14 dan 15 berikut.

$$R_t = \ln\left(\frac{P_t}{P_{t-1}}\right) \quad (14)$$

$$\text{Volatilitas} = R_t^2 \quad (15)$$

Keterangan:
R_t = Return ke-t
P_t = Harga pada waktu ke-t

I. Nilai Tukar Mata Uang (Kurs)

Nilai tukar mata uang (kurs) adalah harga suatu mata uang yang dinyatakan dalam mata uang negara lain dan digunakan sebagai alat tukar dalam transaksi internasional [19]. Nilai tukar menunjukkan berapa banyak mata uang domestik yang diperlukan untuk memperoleh satu unit mata uang asing. Pergerakan nilai tukar dipengaruhi oleh berbagai faktor ekonomi, seperti tingkat inflasi, suku bunga, kondisi perdagangan internasional, stabilitas politik, serta permintaan dan penawaran mata uang di pasar valuta asing [20]. Nilai tukar yang digunakan dalam penelitian ini adalah kurs Rupiah terhadap Dolar Amerika Serikat (USD). Data nilai tukar diperoleh dari Bank Indonesia dan dinyatakan dalam satuan Rupiah per Dolar Amerika Serikat.

III. PETUNJUK TAMBAHAN

A. Sumber Data

Data pada penelitian ini merupakan data sekunder mengenai kurs Rupiah terhadap Dolar Amerika Serikat (USD) yang didapat dari situs https://id.investing.com/. Periode data dimulai dari tanggal 6 Juni 2016 hingga 5 Juni 2026.

B. Variabel Penelitian

Variabel yang digunakan pada penelitian ini Adalah data pergerakan nilai Rupiah terhadap Dolar Amerika Serikat (USD). Struktur dari data tersebut ditunjukkan pada Tabel 3.1 sebagai berikut.

Tabel 3.1
Struktur Data Penelitian

Tanggal	USD to IDR
6/6/2016	13377
7/6/2016	13270
:	:
:	:
4/6/2026	18025
5/6/2026	18015

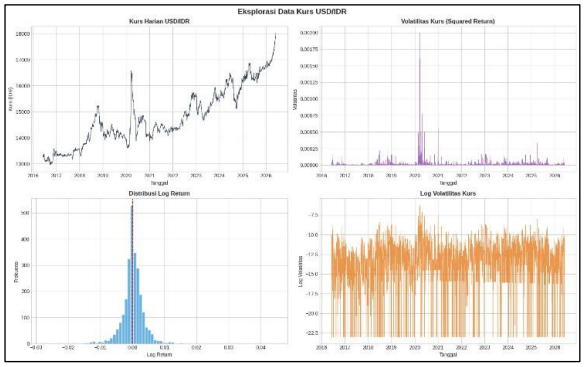
C. Langkah Analisis

Langkah analisis pada penelitian ini adalah sebagai berikut.

1. Mengumpulkan data historis yang digunakan dalam penelitian dari *website* investing.com.
2. Menganalisis karakteristik data melalui statistik deskriptif dan visualisasi untuk memahami pola, tren, serta potensi anomali pada data.
3. Melakukan pembersihan data, menghitung return harian, kemudian mengubahnya menjadi volatilitas menggunakan metode *squared return*. Data selanjutnya dinormalisasi untuk kebutuhan pemodelan.
4. Membagi data ke dalam empat periode validasi menggunakan metode *sliding window* untuk menjaga urutan waktu dan memperoleh evaluasi yang lebih representatif.
5. Menentukan kombinasi hyperparameter terbaik pada model LSTM, GRU, dan CNN menggunakan metode *Random Search*.
6. Mengevaluasi performa model menggunakan RMSE serta menghitung selang kepercayaan 95% untuk mengukur kestabilan hasil prediksi.
7. Menggunakan model terbaik untuk memprediksi volatilitas selama 30 hari mendatang.
8. Menyimpan hasil prediksi dan evaluasi model dalam format yang siap digunakan pada dashboard Streamlit.

IV. ANALISIS PEMBAHASAN

A. *Exploratory Data Analysis*



Berdasarkan hasil eksplorasi data pada Gambar 4.1, kurs harian USD/IDR menunjukkan tren yang cenderung meningkat selama periode pengamatan, dengan beberapa fluktuasi yang cukup tajam pada waktu-waktu tertentu dan mencapai level tertinggi pada akhir periode. Grafik volatilitas yang dihitung menggunakan *squared return* memperlihatkan adanya lonjakan volatilitas yang sangat tinggi pada beberapa titik, terutama sekitar tahun 2020, yang mengindikasikan terjadinya gejolak pasar atau ketidakstabilan nilai tukar. Distribusi log return terlihat terpusat di sekitar nol dengan bentuk yang menyerupai distribusi normal, namun masih terdapat nilai ekstrem pada kedua sisi yang menunjukkan adanya pergerakan kurs yang tidak biasa. Sementara itu, grafik log volatilitas menunjukkan pola yang berfluktuasi sepanjang waktu dengan kemunculan periode volatilitas tinggi dan rendah secara bergantian (*volatility clustering*), yang menandakan bahwa volatilitas kurs bersifat dinamis dan tidak konstan. Secara keseluruhan, hasil EDA menunjukkan bahwa data memiliki karakteristik deret waktu yang kompleks dengan adanya tren, lonjakan volatilitas, dan pola *volatility clustering*, sehingga memerlukan model yang mampu menangkap ketergantungan temporal dan perubahan pola secara efektif.

B. *Pra-pemrosesan Data*

Sebelum data volatilitas kurs dimasukkan ke dalam model deep learning, dilakukan beberapa tahapan pra-pemrosesan untuk memastikan kualitas data dan kestabilan proses pelatihan model. Volatilitas kurs dihitung menggunakan *squared return* dari log return harian sebagai proksi, dengan rumus sebagai berikut:

$$R_t = \ln\left(\frac{P_t}{P_{t-1}}\right)$$

$$\text{Volatilitas} = R_t^2$$

Berdasarkan hasil perhitungan, diperoleh total 2.555 observasi volatilitas dengan rentang tanggal 7 Januari 2016 hingga 5 Desember 2026. Statistik deskriptif data volatilitas disajikan pada Tabel 4.1 berikut

Tabel 4.1 Karakteristik Data

Statistik	Kurs (IDR)	Log Return	Volatilitas
Jumlah Observasi	2.555	2.555	2.555
Rata-rata	14.788,75	0,000112	0,00037
Standar Deviasi	1.112,35	0,019248	0,001784
Minimum	12.947,50	-0,173653	0
Maksimum	18.025,00	0,169696	0,030155

Pada Tabel 4.1 Kurs USD/IDR, log return, dan volatilitas dengan total 2.555 observasi. Kurs USD/IDR memiliki rata-rata Rp14.788,75 dan standar deviasi Rp1.112,35, dengan rentang nilai antara Rp12.947,50 hingga Rp18.025,00, mengindikasikan fluktuasi nilai tukar yang cukup signifikan sepanjang periode pengamatan. Log return memiliki rata-rata mendekati nol (0,000112) dengan nilai ekstrem −0,173653 dan 0,169696, yang mencerminkan karakteristik return harian yang stasioner namun rentan terhadap guncangan ekstrem, sementara volatilitas menunjukkan rata-rata 0,00037 dengan maksimum 0,030155 yang mengindikasikan adanya periode tekanan pasar yang intens pada waktu-waktu tertentu. Normalisasi data menggunakan MinMaxScaler dengan rentang [0, 1] diterapkan pada masing-masing model, di mana scaler di-fit hanya pada data training untuk menghindari data leakage, dan sequences input dibentuk dengan lookback = 10 hari untuk memprediksi satu hari ke depan.

C. *Penentuan Hyperparameter Terbaik melalui Sliding Window Cross-Validation*

Pemilihan hyperparameter terbaik untuk ketiga metode (LSTM, GRU, CNN) dilakukan menggunakan metode *Randomized Search* dengan 10 kombinasi acak yang dievaluasi pada 4 kelompok data hasil *Sliding Window Cross-Validation*. Kriteria pemilihan adalah rata-rata RMSE terkecil dari keempat kelompok. Pembagian data menjadi 4 kelompok dilakukan berdasarkan rentang waktu sebagaimana disajikan pada Tabel 4.2, dengan masing-masing kelompok dibagi 80% data training dan 20% data testing.

Tabel 4.2 Kelompok Pembagian Data

Kelompok	Rentang Waktu	Total Obs	Training	Testing
1	6 Juni 2016 – 31 Des 2018	670	536	134
2	1 Jan 2019 – 30 Jun 2021	625	500	125
3	1 Jul 2021 – 31 Des 2023	624	499	125
4	1 Jan 2024 – 5 Juni 2026	636	508	128
Seluruh Data	6 Jun 2016 – 5 Jun 2026	2.555	2.044	511

Data historis periode 6 Juni 2016–5 Juni 2026 dibagi menjadi empat kelompok waktu yang masing-masing merepresentasikan sekitar 2,5 tahun data. Setiap kelompok kemudian dipisahkan menjadi data pelatihan (80%) dan data pengujian (20%) untuk proses tuning hyperparameter menggunakan pendekatan Sliding Window Cross-Validation. Setelah diperoleh kombinasi hyperparameter terbaik, seluruh

data kembali dibagi menjadi data pelatihan dan pengujian dengan proporsi 80:20 sebagai skema pelatihan dan evaluasi model akhir.

D. Pemodelan Long Short-Term Memory (LSTM)

LSTM merupakan jenis *Recurrent Neural Network* (RNN) yang dirancang untuk menangani masalah *vanishing gradient* pada data sekuensial. LSTM menggunakan tiga gerbang utama, yaitu *forget gate*, *input gate*, dan *output gate*, yang memungkinkan model menyimpan dan memperbarui informasi jangka panjang. Arsitektur LSTM yang digunakan dalam penelitian ini terdiri dari satu LSTM layer, satu Dropout layer, dan satu Dense layer sebagai output. Hyperparameter terbaik yang dipilih disajikan pada Tabel 4.3 berikut

Tabel 4.3 *hyperparameter* Terbaik (LSTM)

Hyperparameter	Nilai Terbaik
Optimizer	Rmsprop
Activation	Tanh
Jumlah Neuron	30
Dropout	0,47
Learning Rate	0,015
Rata-rata RMSE CV	3,086

Dari kombinasi yang diuji menggunakan Randomized Search, diperoleh konfigurasi terbaik LSTM dengan rata-rata RMSE cross-validation sebesar 0,0000309. Model LSTM final dilatih dengan konfigurasi terbaik tersebut, yakni optimizer RMSProp, fungsi aktivasi tanh, 30 neuron, learning rate 0,0152, dan dropout 0,471. Model LSTM final dilatih dengan konfigurasi terbaik tersebut pada data penuh selama 15 epoch (berhenti lebih awal berdasarkan *EarlyStopping* dengan *best epoch* pada *epoch* ke-10).

E. Pemodelan Gated Recurrent Unit (GRU)

GRU merupakan versi yang lebih sederhana dari LSTM, yang menggunakan dua gerbang utama, yaitu *update gate* dan *reset gate*. Arsitektur yang lebih ringkas membuat GRU lebih efisien secara komputasi, namun tetap mampu menangkap ketergantungan temporal dalam data deret waktu. Arsitektur GRU yang digunakan terdiri dari satu GRU layer, satu Dropout layer (rate=0,2), dan satu Dense output layer. Konfigurasi terbaik GRU disajikan dalam tabel 4.4 berikut

Tabel 4.4 *Hyperparameter* Terbaik (GRU)

Hyperparameter	Nilai Terbaik
Units (Layer)	119
Learning Rate	0,001
Epochs (Tuning)	7
Batch Size	64
Dropout	0,283
Rata-rata RMSE CV	3,107

Konfigurasi terbaik GRU diperoleh dengan rata-rata RMSE cross-validation sebesar 0,0000311, dengan parameter optimal berupa 119 unit, learning *rate* 0,00100, dropout 0,284, dan *batch size* 64..

F. Pemodelan Convolutional Neural Network (CNN)

CNN umumnya digunakan dalam pengenalan citra, namun juga efektif untuk data deret waktu melalui kemampuannya mengekstraksi fitur lokal menggunakan filter konvolusi. Arsitektur CNN yang digunakan terdiri dari beberapa Conv1D layer, MaxPooling layer, Flatten layer, beberapa Dense layer, hingga Dense output layer. Hyperparameter terbaik CNN disajikan dalam tabel 4.5 berikut

Tabel 4.5 *Hyperparameter* Terbaik (CNN)

Hyperparameter	Nilai Terbaik
Jumlah Filter	48
Conv. Layers	3
Hidden Layers	3
Layer Units	103
Conv. Dropout	0,1296
Hidden Dropout	0,3604
Activation	Relu
Rata-rata RMSE CV	3,1354

Hyperparameter terbaik CNN diperoleh dengan rata-rata RMSE cross-validation sebesar 0,0000314, dengan konfigurasi optimal berupa 48 filter, 3 convolutional layers, kernel size 2, pool size 2, 3 hidden layers dengan 103 unit, learning rate 0,00223, conv dropout 0,130, hidden dropout 0,360, fungsi aktivasi relu, dan batch size 16. Training final CNN berhenti pada epoch ke-9 (EarlyStopping), dengan *best epoch* pada epoch ke-4.

G. Evaluasi Performa Model berdasarkan Nilai RMSE

RMSE digunakan untuk mengukur seberapa dekat prediksi volatilitas terhadap nilai volatilitas aktual. Semakin kecil nilai RMSE, semakin baik performa model dalam merepresentasikan data. Hasil perbandingan nilai RMSE ketiga model pada data training dan testing disajikan pada Tabel 4.6 berikut

Tabel 4.6 Evaluasi Model (RMSE)

Metode	RMSE Training	RMSE Testing
LSTM	**0,0000661**	**0,0000235**
GRU	0,0000641	0,0000236
CNN	0,0000667	0,0000236

Berdasarkan Tabel 4.6, LSTM menunjukkan nilai RMSE testing terkecil sebesar 0,000023, diikuti GRU dan CNN yang masing-masing sebesar 0,000024. Selisih nilai RMSE antar ketiga metode sangat kecil, mengindikasikan bahwa ketiganya memiliki kemampuan yang hampir setara dalam menangkap pola data deret waktu kurs Rupiah terhadap USD. Meskipun demikian, LSTM sedikit lebih unggul dengan nilai RMSE training sebesar 0,000066, sehingga ditetapkan sebagai model terbaik dalam penelitian ini.

H. Evaluasi Performa Model berdasarkan Selang Kepercayaan

Selain menggunakan RMSE, evaluasi model juga dilakukan melalui pengukuran persentase nilai return aktual

yang berada dalam selang kepercayaan 95% yang dibentuk berdasarkan hasil prediksi volatilitas dari masing-masing model. Penggunaan selang kepercayaan 95% dipilih karena secara statistik interval ini diharapkan mampu mencakup sekitar 95% dari data aktual apabila estimasi volatilitas yang dihasilkan model sudah merepresentasikan tingkat risiko yang sebenarnya. Oleh karena itu, persentase return aktual yang berada di dalam interval tersebut dihitung sebagai indikator kemampuan model dalam menangkap ketidakpastian dan fluktuasi pasar. Semakin mendekati nilai teoritis 95%, semakin baik model dalam menggambarkan risiko yang terjadi pada kondisi pasar nyata. Hasil evaluasi disajikan pada Tabel 4.7.

Tabel 4.7 Evaluasi Model (Selang Kepercayaan)

Metode	CI Training (%)	CI Testing (%)
LSTM	94,25 %	94,32 %
GRU	**94,79 %**	**95,11 %**
CNN	94,49 %	95,11 %

Tabel 4.7 menunjukkan bahwa GRU dan CNN mencatat persentase nilai aktual dalam selang kepercayaan 95% tertinggi pada data testing, masing-masing sebesar 95,11%, tepat mencapai target teoritis. LSTM berada di posisi ketiga dengan 94,32%, sedikit di bawah target. Pada data training, GRU juga mencatat persentase tertinggi sebesar 94,79%, diikuti CNN sebesar 94,49%, dan LSTM sebesar 94,25%. Secara keseluruhan, GRU menunjukkan konsistensi terbaik karena unggul di kedua partisi data sekaligus mencapai target teoritis 95% pada data testing.

I. Penentuan Model Terbaik

Penentuan model terbaik mempertimbangkan kombinasi RMSE dan persentase selang kepercayaan secara bersamaan sebagaimana dirangkum pada Tabel 4.8.

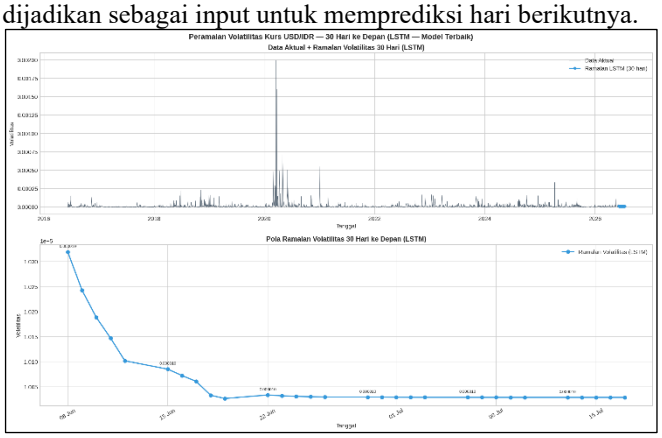
Tabel 4.8 Penentuan Model

Metode	RMSE Train	RMSE Test	CI rain (%)	CI Test (%)
LSTM	**0,0000661**	**0,0000235**	**94,25%**	**94,32%**
GRU	0,0000641	0,0000236	94,79%	95,11%
CNN	0,0000667	0,0000236	94,49%	95,11%

Berdasarkan Tabel 4.8, pemilihan model terbaik mempertimbangkan dua metrik evaluasi secara bersamaan. Dari sisi RMSE testing, LSTM sedikit lebih unggul dengan nilai 0,0000235 dibandingkan GRU dan CNN yang sama-sama mencatat 0,0000236. Namun dari sisi persentase data dalam selang kepercayaan 95% pada data testing, GRU dan CNN keduanya mencapai 95,11%, melampaui LSTM yang hanya 94,32%. Meskipun demikian, dengan mempertimbangkan akurasi prediksi, LSTM ditetapkan sebagai model terbaik karena mencatat RMSE *testing* terkecil (0,0000661) sehingga dipilih untuk melakukan peramalan kurs Rupiah terhadap USD 30 hari ke depan.

J. Peramalan Menggunakan Model Terbaik

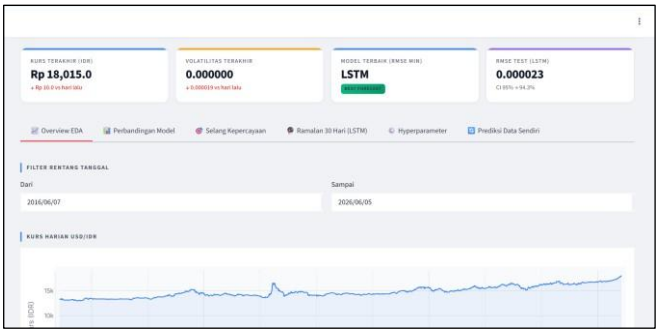
Peramalan volatilitas kurs USD/IDR dilakukan menggunakan model GRU dengan konfigurasi terbaik yang telah diidentifikasi pada tahap evaluasi Metode yang digunakan dalam peramalan adalah *recursive multi-step forecasting* (peramalan rekursif), di mana prediksi setiap hari dijadikan sebagai input untuk memprediksi hari berikutnya.



Gambar 4.2 Evaluasi Performa Model

Berdasarkan Gambar 4.1, pola ramalan menunjukkan tren penurunan nilai volatilitas yang sangat signifikan pada awal periode, dimulai dari titik tertinggi di sekitar tanggal 09 Juni. Penurunan tajam ini terus berlanjut hingga melewati pertengahan Juni, lalu melandai secara bertahap menuju akhir bulan. Setelah memasuki tanggal 23 Jun hingga akhir periode peramalan di pertengahan Juli, grafik peramalan volatilitas model LSTM ini menunjukkan pergerakan yang sangat stabil, konstan, dan mendatar tanpa ada fluktuasi yang berarti.

K. Dashboard



Gambar 4.3 Dashboard Berbasis Streamlit

Dashboard interaktif dapat diakses pada tautan berikut: https://its.id/m/DashboardKelompok7

V. PENUTUP

A. KESIMPULAN

1. Ketiga metode deep learning (LSTM, GRU, CNN) berhasil diterapkan untuk meramalkan volatilitas kurs USD/IDR menggunakan data harian dari 6 Juni 2016 hingga 5 Juni 2026 dengan total 2.555 observasi.
2. Proses pemilihan hyperparameter terbaik dilakukan melalui Randomized Search dengan 20 iterasi pada 4 kelompok Sliding Window Cross-Validation. Konfigurasi terbaik yang diperoleh adalah: LSTM (Adam, 64 neuron, aktivasi relu), GRU (units 16–256 acak, learning rate log-uniform), dan CNN (filter 16–128 acak, 1–4 conv layers, 1–3 hidden layers, 32–128 units, aktivasi relu/tanh).
3. Berdasarkan nilai RMSE pada data testing, LSTM unggul dengan RMSE sebesar 0,0000235, diikuti GRU (0,0000236) dan CNN (0,0000236). Selisih antar metode sangat kecil, namun LSTM mengungguli kedua model lainnya.
4. Berdasarkan persentase nilai aktual dalam selang kepercayaan 95%, GRU dan CNN memiliki nilai setara dengan persentase 95,11% pada data testing, diikuti LSTM (94,32%).

5. LSTM ditetapkan sebagai model terbaik secara keseluruhan karena unggul metrik evaluasi RMSE. Peramalan 30 hari ke depan menggunakan LSTM mengindikasikan kondisi pasar kurs diperkirakan relatif stabil.

B. SARAN

Penelitian selanjutnya disarankan untuk mengeksplorasi model hybrid yang menggabungkan GRU dengan mekanisme attention atau arsitektur Transformer guna meningkatkan akurasi peramalan volatilitas kurs USD/IDR, terutama pada periode gejolak pasar yang ekstrem. Bagi pembaca atau praktisi yang memerlukan referensi peramalan volatilitas jangka pendek, model GRU dapat dijadikan acuan utama mengingat konsistensinya pada kedua metrik evaluasi, namun tetap perlu mempertimbangkan dinamika pasar terkini sebelum mengambil keputusan berbasis prediksi model.

LAMPIRAN

1. LAMPIRAN DATA

Tanggal	USD to IDR
6/6/2016	13377
7/6/2016	13270
:	:
1/6/2017	13322
2/6/2017	13304
:	:
1/6/2018	13895
4/6/2018	13872
:	:
4/6/2026	18025
5/6/2026	18015

Dataset lengkap dapat dilihat pada: https://its.id/m/DataUSDtoIDR.

DAFTAR PUSTAKA

[1] Kevin, R. J. Iskandar, dan S. Tendean, "Model Hybrid LSTM-XGBoost untuk Prediksi Nilai Tukar Rupiah Terhadap Dolar Amerika," *J. Widyadharma*, vol. 10, Okt 2025.

[2] W. Elvan, "Rupiah Kembali Melemah, Dolar AS Naik Jadi Rp 17.975." [Daring]. Tersedia pada: https://www.cnbcindonesia.com/market/20260611145712-17-742047/rupiah-kembali-melemah-dolar-as-naik-jadi-rp-17975

[3] A. V. Septiani, F. M. Afendi, dan A. Kurnia, "Perbandingan Metode GARCH, LSTM, GRU, dan CNN pada Peramalan Volatilitas Kurs," *Limits J. Math. Its Appl.*, vol. 22, no. 1, hlm. 147–167, Mar 2025, doi: 10.12962/limits.v22i1.3384.

[4] A. J. Noor, D. A. Kurnia, Y. A. Wijaya, dan H. Susana, "Perbandingan Model LSTM dan GRU untuk Prediksi Harga Saham Telekomunikasi Indonesia," *J. Mhs. Ilmu Komput. JMIK*, vol. 7, no. 1, 2026.

[5] R. S. Andromeda dan N. A. S. Winarsih, "Perbandingan Kinerja Metode LSTM dan GRU dalam Prediksi Harga *Close Cryptocurrency*," *Sist. J. Sist. Inf.*, vol. 14, no. 1, 2025.

[6] I. Ramdhani dan R. Erniyani, "Peramalan Permintaan Produk Bakso Frozen FA Menggunakan Metode *Time Series*," *Fact. J. Ind. Manaj. dan Rekayasa Sist. Ind.*, vol. 4, no. 2, 2025.

[7] L. N. Halimah, S. Riyadi, Abdurrahman, A. F. Jurjani, A. Prayogi, dan S. D. Laksana, "Implementasi Penggunaan *Machine Learning* dalam Pembelajaran: Suatu Telaah Deskriptif," *Reskilling J. Penelit. Pendidik.*, vol. 1, no. 1, 2025.

[8] B. M. Hermawan, M. A. Hakim, R. Arifin, dan N. Puspitasari, "Pemanfaatan *Artificial Intellegence*, Khususnya *Machine Learning* dan *Deep Learning System* dalam Pendidikan," *Semin. Nas. AMIKOM Surak. SEMNASA*, vol. 2, Nov 2024.

[9] A. Tholib, N. K. Agusmawati, dan F. Khoiriyah, "Prediksi Harga Emas Menggunakan Metode LSTM dan GRU," *J. Inform. dan Tek. Elektro Terap.*, vol. 11, no. 3, Agu 2023, doi: 10.23960/jitet.v11i3.3250.

[10] D. A. Adha, A. Ramadhan, H. Maulana, P. P. H. Harahap, dan E. Ismanto, "*Gold Price Forecasting Based on Time Series Using the LSTM Deep Learning Architecture*," *J. Comput. Sci. Inf. Technol. CoSciTech*, vol. 6, no. 2, 2025.

[11] R. W. Akbari, A. Prayogo, dan A. Jahir, "*Comparative Study of LSTM and GRU Accuracy in Predicting BBRI Stock Closing Price*," *J. Appl. Inform. Comput.*, vol. 10, no. 1, hlm. 837–846, Feb 2026, doi: 10.30871/jaic.v10i1.11938.

[12] Y. Perdana, N. Raisa Hanum, A. Rabiula, dan Y. Anzari, "Analisis Perbandingan Model GRU dan LSTM untuk Prediksi Harga Saham Bank Rakyat Indonesia: *Deep Learning*, GRU (*Gated Recurrent Unit*), LSTM (*Long Short-Term Memory*), *Stock Price Prediction*," *J. Akad.*, vol. 17, no. 2, hlm. 54–60, Jun 2025, doi: 10.53564/akademika.v17i2.1692.

[13] L. F. Olivia, Y. Yuhandri, dan S. Arlis, "Penerapan *Deep Learning* Menggunakan Metode *Convolutional Neural Network* dan K-Means dalam Klasterisasi Citra Butiran Pasir," *J. KomtekInfo*, hlm. 54–62, Mar 2025, doi: 10.35134/komtekinfo.v12i1.629.

[14] N. Chalista Imanuela Natun, M. Angelica Santhia, dan Y. R. Kaesmetan, "Identifikasi Pengenalan Wajah Berdasarkan Jenis Kelamin Menggunakan Metode *Convolutional Neural Network* (CNN)," *J. Technol. Inform. JoTI*, vol. 6, no. 1, hlm. 50–57, Okt 2024, doi: 10.37802/joti.v6i1.694.

[15] H. A. Anamsyah, I. G. S. M. Diyasa, dan A. N. Sihananto, "Perbandingan Model XGBoost, LSTM, dan *Neural Prophet* untuk Prediksi Harga Cabai Rawit Merah di Jawa Timur," *Semin. Nas. Inform. Bela Negara SANTIKA*, vol. 5, no. 2, Des 2025, Diakses: 3 April 2026. [Daring]. Tersedia pada: https://santika.upnjatim.ac.id/submissions/index.php/santika/article/view/836

[16] K. Mawadah dan A. Oktaviarina, "Perbandingan Model ARIMA dan *Hybrid* ARIMA-*Random Forest* untuk Peramalan Harga Bawang Merah Harian di Provinsi Jawa Timur," *Imajiner J. Mat. Dan Pendidik. Mat.*, vol. 8, no. 2, 2026, [Daring]. Tersedia pada: http://journal.upgris.ac.id/index.php/imajiner

[17] H. Najmi Hawa, A. Fauzi, F. F. Putra, G. P. Naraya, G. V. Nazara, dan I. A. Wa'afin, "Analisis Risiko dan Tingkat Pengembalian dalam Mengidentifikasi Saham yang Dimiliki Investor," *J. Pendidik. Siber Nusant.*,

vol. 1, no. 4, hlm. 117–128, Des 2023, doi: 10.38035/jpsn.v1i4.99.

[18] M. H. Sinaga, W. J. Tarigan, dan M. Saragih, "Pengukuran Kinerja Portofolio Investasi dengan Menggunakan Indeks Sharpe pada Emiten Sektor Transportasi dan Logistik yang Terdaftar di Bursa Efek Indonesia Sebelum dan Selama Masa Pandemi Covid - 19," *Owner*, vol. 6, no. 4, hlm. 3541–3552, Okt 2022, doi: 10.33395/owner.v6i4.1200.

[19] D. Christine, Apriwandi, dan R. Hidayat, "Pengaruh Inflasi, Suku Bunga dan Nilai Tukar Terhadap *Return* Saham," *J. Ekuilnomi*, vol. 5, no. 2, hlm. 237–244, Nov 2023, doi: 10.36985/83dk5d10.

[20] N. Achmadi, "Analisis Pengaruh Inflasi, Suku Bunga, Nilai Tukar Terhadap Harga Saham," *J. Ris. Akunt. Mercu Buana*, vol. 9, no. 2, 2023.